

机器学习 第10章 作业

10.1

```
import numpy as np
import matplotlib.pyplot as plt

#设置绘图时显示中文
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus'] = False

def knn(X,Y,Xpre,k,p=2):
    # k近邻算法
    # X: 样本数据
    # Y: 样本标记
    # Xpre: 待预测样本
    # k: k近邻的k值
    # p:计算距离所采用的闵可夫斯基距离的p值
    mt,n=X.shape          #训练样本数和特征数
    Xpre=np.array(Xpre).reshape(-1,n)
    mp=Xpre.shape[0]      #预测样本数
    dist=np.zeros([mp,mt]) #存储预测样本和训练样本之间的距离
    for i in range(mt):
        dist[:,i]=(((abs(Xpre-X[i]))**p).sum(axis=1))**(1/p))
    neighbor=np.argsort(dist,axis=1) #训练样本按距离远近排序的索引号
    neighbor=neighbor[:, :k]        #只取前k个作为最近邻
    Ypre=Y[neighbor]
    return (Ypre.sum(axis=1)>=0)*2-1 #西瓜3.0α仅两类，故可如此计算

# 西瓜3.0α 样本数据
X=np.array([[0.697,0.46],[0.774,0.376],[0.634,0.264],[0.608,0.318],[0.556,0.215],
            [0.403,0.237],[0.481,0.149],[0.437,0.211],[0.666,0.091],[0.243,0.267],
            [0.245,0.057],[0.343,0.099],[0.639,0.161],[0.657,0.198],[0.36,0.37],
            [0.593,0.042],[0.719,0.103]])
Y=np.array([1,1,1,1,1,1,1,1,-1,-1,-1,-1,-1,-1,-1,-1,-1,-1])

# 执行knn算法
# 尝试 k=1,3,5,p=1,2,30的不同情况
ks=[1,3,5]
ps=[1,2,50] #p=1为曼哈顿距离，p=2为欧式距离，p=50(→∞)为切比雪夫距离
for i,k in enumerate(ks):
    for j,p in enumerate(ps):
        # knn算法预测结果
        x0=np.linspace(min(X[:,0]),max(X[:,0]),60)
        x1=np.linspace(min(X[:,1]),max(X[:,1]),60)
        X0,X1=np.meshgrid(x0,x1)
        Xpre=np.c_[X0.reshape(-1,1),X1.reshape(-1,1)]
        Ypre=knn(X,Y,Xpre,k,p).reshape(X0.shape)
        # 画图
        plt.subplot(len(ks),len(ps),i*len(ps)+j+1)
        #plt.axis('equal')
        plt.title('k=%d,p=%d'%(k,p))
        plt.xlabel('密度')
```

```
plt.ylabel('含糖率')
# 画样本点
plt.scatter(X[Y==1,0],X[Y==1,1],marker='+',s=30,label='好瓜')
plt.scatter(X[Y==-1,0],X[Y==-1,1],marker='_',s=30,label='坏瓜')
# 画决策树边界 (直接根据教材上图4.10和4.11确定边界曲线坐标)
plt.plot([0.381,0.381,0.56,0.56,max(X[:,0])],
         [max(X[:,1]),0.126,0.126,0.205,0.205], 'k', label='决策树边界')
# 画kNN边界
plt.contour(x0,x1,ypr,1,colors='r',s=2)
plt.show()
```

讨论:

1. 当 $k=1$ 时训练误差为零; 当 k 越来越大时, 分类边界趋向平缓, 会出现训练样本误分类的情况, 此时为欠拟合。可见, k 越小越容易过拟合, k 越大越容易欠拟合。
2. 不同 p 值的距离计算下, 差别不太明显。

10.2

证明: 首先来理解一下这两个期望错误率, 它们都表示成"错误率=1-正确率"的形式, 因此问题转化成理解正确率。对于预测样本 x , 贝叶斯最优分类器的决策结果 c^* , 如果预测正确, 意味着这个样本的真实类别刚好也是 c^* , 而该样本以 $P(c^*|x)$ 的概率属于 c^* 类别, 因此预测正确的概率即为 $P(c^*|x)$, 而错误率 $err^* = 1 - P(c^*|x)$ 。

最近邻分类器的决策结果等于近邻样本 z 相同的类别, 假设这个共同的类别为 c , 如果这个决策结果是正确的, 意味着 x 样本和 z 样本刚好都属于 c 类, 这个事件发生的概率是 $P(c|x)P(c|z)$ 。考虑各种不同的 c 值, 把它们加起来便是总的期望正确率 $= \sum_c P(c|x)P(c|z)$, 因此错误率 $err = 1 - \sum_c P(c|x)P(c|z)$ 。

接下来证明上面的不等式:

$$\begin{aligned} err &= 1 - \sum_c P(c|x)P(c|z) \\ &\geq 1 - \sum_c P(c^*|x)P(c|z) \\ &= 1 - P(c^*|x) \cdot \sum_c P(c|z) \\ &= 1 - P(c^*|x) \\ &= err^* \end{aligned}$$

第2行利用了关系 $P(c|x) \leq P(c^*|x)$, 第4行利用了关系 $\sum_c P(c|z) = 1$ 。

不等式左半边得证。

$$\begin{aligned} err &= 1 - \sum_c P(c|x)P(c|z) \\ &\approx 1 - \sum_c P^2(c|x) \\ &= 1 - P^2(c^*|x) - \sum_{c \neq c^*} P^2(c|x) \\ &\leq 1 - P^2(c^*|x) - \frac{[\sum_{c \neq c^*} P(c|x)]^2}{|y| - 1} \\ &= 1 - (1 - err^*)^2 - \frac{(err^*)^2}{|y| - 1} \\ &= err^* (2 - \frac{|y|}{|y| - 1} err^*) \end{aligned}$$

第4行利用了不等式关系: $\frac{\sum a_i^2}{n} \geq (\frac{\sum a_i}{n})^2$, $a_i \geq 0, i = 1, 2, \dots, n$; 第5行利用了关系

$$\sum_c \neq c^* P(c|x) = 1 - P(c^*|x) = err^*.$$

不等式右半边得证。

10.3

答：相当于将 X 变为 X' ：

$$\begin{aligned} X' &= XH \\ &= X(I - \frac{1}{m}11^T) \\ &= X - \frac{1}{m}X11^T \\ &= X - \frac{1}{m}[x_1, \quad x_2, \quad \dots] \begin{bmatrix} 1 \\ 1 \\ \vdots \end{bmatrix} [1 \quad 1 \quad \dots] \\ &= X - \frac{1}{m} \sum_i x_i [1 \quad 1 \quad \dots] \\ &= X - \bar{x} [1 \quad 1 \quad \dots] \\ &= [x_1 - \bar{x}, \quad x_2 - \bar{x}, \quad \dots] \end{aligned}$$

其效果便是中心化 $x'_i = x_i - \bar{x}$ 。

10.4

答：首先看一下，确实可以通过SVD(奇异值)分解得到协方差矩阵的特征值和特征向量。由附录A.33式有，任意实矩阵 $A \in R^{m \times n}$ 都可以分解为 $A = U\Sigma V^T$ 。

其中 U 和 V 分别为 m 阶和 n 阶的正交矩阵， Σ 是 $m \times n$ 矩阵，对角元以外元素均为零，于是有：

$$\begin{aligned} AA^T &= U\Sigma V^T V\Sigma^T U^T = U\Sigma\Sigma^T U^T \\ A^T A &= V\Sigma^T U^T U\Sigma V^T = V\Sigma^T \Sigma V^T \end{aligned}$$

因此， U 的列向量是 AA^T 的特征向量， V 的列向量是 $A^T A$ 的特征向量， Σ 矩阵的非零对角元 σ_{ii} 的平方即为 AA^T 和 $A^T A$ 的共同非零特征值。

在前面原理介绍部分采用的10.2和10.4等图中，数据维度 $d=2$ 或 3 ，而样本数 m 远大于数据维数， $m \gg d$ 。然而在实际情况下，既然需要降维，通常维度 d 很大，比如对于100张 100×100 的图片， $m=100$ ， $d=10000$ ，此时的协方差矩阵 XX^T 的shape为 $R^{10000 \times 10000}$ ，矩阵维度较大。而 $X \in R^{10000 \times 100}$ ，对其进行SVD(奇异值)分解的计算成本较低一些。